

基于滤波的激光SLAM方法(Grid-based)



主讲人 曾书格

越凡创新技术负责人
597457483@qq.com



Filter-based SLAM



1、贝叶斯滤波



2、粒子滤波



3、FastSLAM的原理及优化



4、Gmapping的介绍



Filter-based SLAM



1、贝叶斯滤波



2、粒子滤波



3、FastSLAM的原理及优化



4、Gmapping的介绍



贝叶斯估计



数学概念

独立:

$$p(x, y) = p(x)p(y)$$

$$p(x|y) = p(x)$$

$$p(y|x) = p(y)$$

条件独立:

$$p(x, y|z) = p(x|z)p(y|z)$$

$$p(x|y, z) = p(x|z)$$

$$p(y|x, z) = p(y|z)$$

全概率公式:

$$p(x) = \int p(x|y)p(y)dy$$

条件概率公式:

$$P(x, y) = P(x|y)P(y) = P(y|x)P(x)$$

贝叶斯公式:

$$p(x, y) = p(x|y)p(y) = p(y|x)p(x)$$

$$\rightarrow p(x|y) = \frac{p(y|x)p(x)}{p(y)} = \eta p(y|x)p(x)$$

条件贝叶斯公式:

$$p(x|y, z) = \frac{p(y|x, z)p(x|z)}{p(y|z)} = \eta p(y|x, z)p(x|z)$$



贝叶斯滤波介绍



贝叶斯滤波特性

- 1. 估计的是概率分布，不是具体的数值
- 2. 是一大类方法的统称
- 3. 是一个抽象的表达形式—对于不同问题有不同的实现方式(卡尔曼家族、粒子滤波)
- 4. 迭代估计形式



贝叶斯滤波



贝叶斯滤波的推导

$$bel(x_t) = p(x_t | z_{1:t}, u_{1:t}) = \eta p(z_t | x_t) \overline{bel}(x_t) = \eta p(z_t | x_t) \int p(x_t | x_{t-1}, u_t) p(x_{t-1} | z_{1:t-1}, u_{1:t-1}) dx_{t-1}$$

```

1:  Algorithm Bayes_filter( $bel(x_{t-1}), u_t, z_t$ ):
2:      for all  $x_t$  do
3:           $\overline{bel}(x_t) = \int p(x_t | u_t, x_{t-1}) bel(x_{t-1}) dx_{t-1}$ 
4:           $bel(x_t) = \eta p(z_t | x_t) \overline{bel}(x_t)$ 
5:      endfor
6:      return  $bel(x_t)$ 

```

功能:

已知状态量 $t-1$ 时刻的概率分布，
在给定 t 时刻的观测数据(z_t, u_z)的情况下
估计出状态量在 t 时刻的概率分布

贝叶斯滤波流程



贝叶斯滤波



贝叶斯滤波的推导

目标：在已知 $p(x_{t-1}|z_{1:t-1}, u_{1:t-1})$ 、 u_t 、 z_t 的情况下，得到 $p(x_t|z_{1:t}, u_{1:t})$ 的表达式。

$$\begin{aligned} p(x_t|z_{1:t}, u_{1:t}) &= \frac{p(z_t|x_t, z_{1:t-1}, u_{1:t})p(x_t|z_{1:t-1}, u_{1:t})}{p(z_t|z_{1:t-1}, u_{1:t})} \\ &= \eta p(z_t|x_t, z_{1:t-1}, u_{1:t})p(x_t|z_{1:t-1}, u_{1:t}) \end{aligned}$$

其中：

$$p(z_t|x_t, z_{1:t-1}, u_{1:t}) = p(z_t|x_t)$$

$$p(x_t|z_{1:t-1}, u_{1:t}) = \int p(x_t|x_{t-1}, z_{1:t-1}, u_{1:t})p(x_{t-1}|z_{1:t-1}, u_{1:t})dx_{t-1}$$

$$p(x_t|x_{t-1}, z_{1:t-1}, u_{1:t}) = p(x_t|x_{t-1}, u_t)$$

$$p(x_{t-1}|z_{1:t-1}, u_{1:t}) = p(x_{t-1}|z_{1:t-1}, u_{1:t-1})$$

令：

$$bel(x_t) = p(x_t|z_{1:t}, u_{1:t})$$

$$\overline{bel}(x_t) = p(x_t|z_{1:t-1}, u_{1:t})$$

$bel(x_t)$ 表示 x_t 的后延概率分布

$\overline{bel}(x_t)$ 表示 x_t 的预测(*proposal*)概率分布

则：

$$bel(x_t) = \eta p(z_t|x_t)\overline{bel}(x_t)$$

$$\begin{aligned} \overline{bel}(x_t) &= \\ &\int p(x_t|x_{t-1}, u_t) p(x_{t-1}|z_{1:t-1}, u_{1:t-1})dx_{t-1} \end{aligned}$$




贝叶斯滤波



贝叶斯滤波实例

$$\begin{aligned} \text{bel}(x_t) &= p(x_t | z_{1:t}, u_{1:t}) \\ &= \eta p(x_t | z_t) \overline{\text{bel}}(x_t) \\ &= \eta p(x_t | z_t) \int p(x_t | x_{t-1}, u_t) p(x_{t-1} | z_{1:t-1}, u_{1:t-1}) dx_{t-1} \end{aligned}$$





Filter-based SLAM



1、贝叶斯滤波



2、粒子滤波



3、FastSLAM的原理及优化



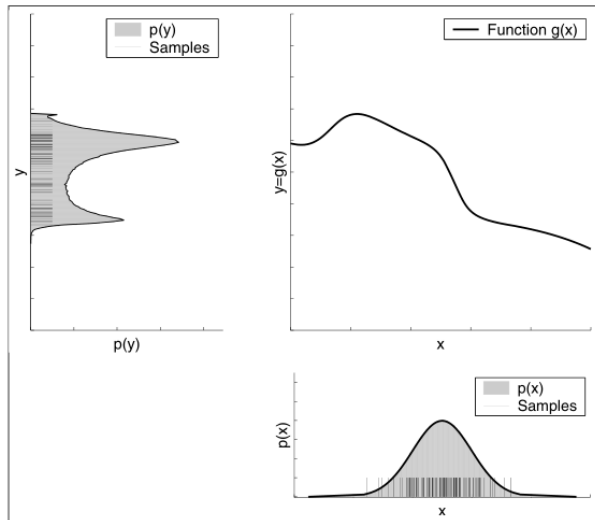
4、Gmapping的介绍



粒子滤波器



示意图



粒子近似分布示意图



特性

- 贝叶斯估计器的一种实现方式
- 能处理非线性情况
- 能处理多峰分布的情况
- 用一系列的粒子(particle)近似概率分布
- 非参滤波器



粒子滤波器




示意图

$$X = \{(x_t^i, w_t^i) | i = 1, \dots, n\}$$

x_t^i 表示一个状态的假设 —— 机器人位姿

w_t^i 表示假设的权重 —— 跟地图的匹配度



流程

- 1. 用粒子进行状态传播


$$x_t^i \sim p(x_t | u_t, x_{t-1}^i)$$

- 2. 评估每一个粒子的权重

$$w_t^i = \eta p(z_t | x_t)$$

- 3. 根据权重进行重采样

以 w_t^i 的概率接受 x_t^i , 权重清零





粒子滤波器



状态传播

传播模型:

$$\overline{bel}(x_t) = \int p(x_t | x_{t-1}, u_t) p(x_{t-1} | z_{1:t-1}, u_{1:t-1}) dx_{t-1}$$

已知 $t - 1$ 时刻的概率分布(粒子分布):

$$p(x_{t-1} | z_{1:t-1}, u_{1:t-1}) = \{(x_{t-1}^i, w_{t-1}^i) | i = 1, \dots, n\}$$

根据数据 u_t 预测 $t - 1$ 时刻的概率分布(粒子分布):

$$x_t^i \sim p(x_t | u_t, x_{t-1}^i)$$

$$i = 1, \dots, n$$



粒子滤波器



状态传播

运动学模型回顾：

$$\begin{bmatrix} x \\ y \\ \theta \end{bmatrix} = \begin{bmatrix} x \\ y \\ \theta \end{bmatrix} + \begin{bmatrix} \cos \theta & -\sin \theta & 0 \\ \sin \theta & \cos \theta & 0 \\ 0 & 0 & 1 \end{bmatrix} \begin{bmatrix} dx + \varepsilon_x \\ dy + \varepsilon_y \\ d\theta + \varepsilon_\theta \end{bmatrix}$$

从预测分布即为运动学模型中进行采样：

设 $t-1$ 时刻第 i 个粒子的位姿 $x_{t-1}^i = (x_{t-1}, y_{t-1}, \theta_{t-1})$


设 $t-1$ 时刻的 $u_t = (\Delta x, \Delta y, \Delta \theta)$

设 t 时刻第 i 个粒子的位姿 $x_t^i = (x_t, y_t, \theta_t)$

噪声为为0均值的高斯分布，分别为 N_x, N_y, N_z

因此：

$$\begin{bmatrix} x_t \\ y_t \\ \theta_t \end{bmatrix} = \begin{bmatrix} x_{t-1} \\ y_{t-1} \\ \theta_{t-1} \end{bmatrix} + \begin{bmatrix} \cos \theta_{t-1} & -\sin \theta_{t-1} & 0 \\ \sin \theta_{t-1} & \cos \theta_{t-1} & 0 \\ 0 & 0 & 1 \end{bmatrix} \begin{bmatrix} \Delta x + N_x \\ \Delta y + N_y \\ \Delta \theta + N_\theta \end{bmatrix}$$





粒子滤波器



权重评估

- 无法知道机器人位姿的实际分布
- 从机器人的预测分布进行采样，联合权重一起近似机器人的后延概率分布
- 权重用来评估实际人的预测分布和实际分布的差，差越大，权重越小。
- 权重的定义：

$$w = \frac{\text{bel}(x_t)}{\overline{\text{bel}}(x_t)}$$

对于某一个粒子：

$$\text{bel}(x_t) = \eta p(z_t|x_t)p(x_t|x_{t-1}, u_t)\text{bel}(x_{t-1})$$

$$\overline{\text{bel}}(x_t) = p(x_t|x_{t-1}, u_t)\text{bel}(x_{t-1})$$

因此权重为：

$$w = \frac{\eta p(z_t|x_t)p(x_t|x_{t-1}, u_t)\text{bel}(x_{t-1})}{p(x_t|x_{t-1}, u_t) \text{bel}(x_{t-1})}$$

$$= \eta p(z_t|x_t)$$


$w_i = w_{i-1}p(z_t|x_t)$ --- 不重采样的更新方式




粒子滤波器



权重评估



proposal采样



权重评估




粒子滤波器



重采样

- 到目前为止，新的粒子群是根据 proposal 分布进行采样的，并且用观测模型计算权重，而最终的目的是用粒子群来近似后延概率分布
- 对粒子群进行重采样，对于某一个粒子 x_i 来说，以 w_i 的概率接受这个粒子。
- 生成一个随机数，根据其落在的区间决定接受的粒子，重复N次。




重采样示意图




粒子滤波器



权重评估



权重评估



重采样后的粒子分布



粒子滤波器



算法流程

```
1: Algorithm Particle_filter( $\mathcal{X}_{t-1}, u_t, z_t$ ):  
2:    $\tilde{\mathcal{X}}_t = \mathcal{X}_t = \emptyset$   
3:   for  $m = 1$  to  $M$  do  
4:     sample  $x_t^{[m]} \sim p(x_t \mid u_t, x_{t-1}^{[m]})$   
5:      $w_t^{[m]} = p(z_t \mid x_t^{[m]})$   
6:      $\tilde{\mathcal{X}}_t = \tilde{\mathcal{X}}_t + \langle x_t^{[m]}, w_t^{[m]} \rangle$   
7:   endfor  
8:   for  $m = 1$  to  $M$  do  
9:     draw  $i$  with probability  $\propto w_t^{[i]}$   
10:    add  $x_t^{[i]}$  to  $\mathcal{X}_t$   
11:  endfor  
12:  return  $\mathcal{X}_t$ 
```



存在的问题

- 粒子耗散问题
- 维数灾难
- 当proposal比较差的时候，需要用很多的粒子才能较好的表示机器人的后延概率分布



Filter-based SLAM



1、贝叶斯滤波



2、粒子滤波



3、FastSLAM的原理及优化



4、Gmapping的介绍



Fast-SLAM原理



Fast-SLAM介绍

- SLAM: 在给定传感器数据的情况下, 同时估计机器人位姿和环境地图:

$$p(x_{1:t}, m | u_{1:t}, z_{1:t})$$

- SLAM可以分解成两个问题:
 1. 机器人的定位
 2. 基于已知机器人位姿的构图

$$\begin{aligned} & p(x_{1:t}, m | u_{1:t}, z_{1:t}) \\ &= p(x_{1:t} | u_{1:t}, z_{1:t}) p(m | x_{1:t}, u_{1:t}, z_{1:t}) \\ &= p(x_{1:t} | u_{1:t}, z_{1:t}) p(m | x_{1:t}, z_{1:t}) \end{aligned}$$

$p(x_{1:t} | u_{1:t}, z_{1:t})$ 为估计机器人路径

$p(m | x_{1:t}, z_{1:t})$ 为给定机器人位姿和传感器观测数据的情况, 进行地图构建。本问题可以实现close-form的求解。

- 用粒子滤波来估计机器人的位姿, 然后分别为每一个粒子计算地图即可。因此一个粒子包含以下数据:
 1. 机器人的轨迹 $x_{1:t}$
 2. 对应的环境地图



算法流程

- 回顾贝叶斯公式和贝叶斯估计，可得：

$$\begin{aligned} p(x_{1:t}|u_{1:t}, z_{1:t}) &= \eta p(z_t|x_{1:t}, u_{1:t}, z_{1:t-1})p(x_{1:t}|z_{1:t-1}, u_{1:t}) \\ &= \eta p(z_t|x_t)p(x_{1:t}|z_{1:t-1}, u_{1:t}) \\ &= \eta p(z_t|x_t)p(x_t|x_{1:t-1}, z_{1:t-1}, u_{1:t})p(x_{1:t-1}|z_{1:t-1}, u_{1:t}) \\ &= \eta p(z_t|x_t)p(x_t|x_{t-1}, u_t)p(x_{1:t-1}|z_{1:t-1}, u_{1:t-1}) \end{aligned}$$

- 上式把对 $x_{1:t}$ 的估计，转换为一个增量估计问题
- $p(x_{1:t-1}|z_{1:t-1}, u_{1:t-1})$ 用粒子群表示
- 每个粒子用运动学模型 $p(x_t|x_{t-1}, u_t)$ 进行传播
- 对于传播之后的粒子，用观测模型进行权重计算，并且根据估计的位姿构建地图。



Fast-SLAM优化--1



存在的问题及优化

- 问题：每一个粒子都包含自己的栅格地图。对于稍微大一点的环境来说，每一个粒子都会占用比较大的内存。如果机器人的里程计误差比较大，即proposal分布跟实际分布相差较大，则需要较多的粒子才能比较好的表示机器人位姿的后延概率分布，会造成内存爆炸
- 目的：要保持粒子的数量在一个比较小的数值。
- 方法：提升proposal分布采样的位姿质量。

$$x_t^i \sim p(x_t | u_t, x_{t-1}^i) \quad \rightarrow \quad x_t^i = \arg \max_{x_t} \{p(z_t | x_t, m) p(x_t | u_t, x_{t-1}^i)\}$$



Fast-SLAM优化--2



存在的问题及优化

- 问题：粒子耗散问题，因此每一次进行重采样都有一定的随机性。随着重采样次数的加多，粒子的多样性会耗散掉，即最终的所有粒子都来自同一个粒子或者少数的几个粒子的复制。
- 目的：尽量缓解粒子耗散的问题。
- 方法：减少重采样的次数，用一个量来表示当前估计和真实分布的差异性：

$$N_{eff} = \frac{1}{\sum (w^i)^2}$$

当 N_{eff} 较大时，说明差异性很小，不进行重采样；

当 N_{eff} 较小时，说明差异性很大，因此进行重采样。

极大的减少了重采样的次数，缓解了粒子耗散问题




Fast-SLAM优化--3



进一步优化proposal分布

- 上面的优化方式：首先从proposal分布进行采样，然后进行极大似然估计提升采样的质量。
- 本次优化方式：考虑最近一帧的观测，把proposal分布限制在一个狭小的有效区域。然后在正常的对proposal分布进行采样。
- 假设：




激光雷达的匹配比里程计的测量精确很多，从分布上来说，激光雷达匹配的方差要比里程计模型的方差小很多



Fast-SLAM优化--3



进一步优化proposal分布



- 如图所示，激光匹配的方差比里程计要小很多，如果proposal分布用激光匹配来表示，则可以把采样范围限制在一个比较小的区域，因此可以用更少的粒子即覆盖机器人的概率分布。

- Proposal分布：

$$p(x_t|x_{t-1}, u_t) \rightarrow p(x_t|x_{t-1}, u_t, z_t, m)$$

$$p(x_t|x_{t-1}, u_t, z_t, m) = \eta p(z_t|x_t, m) p(x_t|x_{t-1}, u_t)$$

- $p(z_t|x_t, m)$ 在自己的区域($L^{(i)}$)占主导地位，此时 $p(x_t|x_{t-1}, u_t)$ 的值不再重要，令其为常数，因此：

$$p(x_t|x_{t-1}, u_t, z_t, m) = \eta p(z_t|x_t, m) \quad x_t \in L^{(i)}$$

- 即proposal分布从里程计观测模型变换到了激光雷达观测模型




进一步优化proposal分布

- 激光雷达观测模型的方差较小，假设其服从高斯分布：

$$p(x_t | x_{t-1}, u_t, z_t, m) \cong N(\mu, \Sigma)$$

maximum reported
by a scan matcher



- 高斯分布的求解：

1. 极大似然估计得到局部极值

$$x_t^* = \arg \max_{x_t} \{p(z_t | x_t, m) p(x_t | u_t, x_{t-1}^i)\}$$

2. 认为 x_t^* 离高斯分布的均值比较近，因此在 x_t^* 附近采样得到K个位姿。

$$\{x_j | |x_j - x_t^*| < \Delta\}$$

3. 对这K个位姿进行打分 $p(z_t | x_j, m)$ ，并认为这K个位姿服从高斯分布，即可求解得到高斯分布的表达式。



进一步优化proposal分布

- 高斯分布的表达式:

$$\mu = \frac{1}{\eta} \sum_{j=1}^K x_j p(z_t | x_j, m)$$

$$\Sigma = \frac{1}{\eta} \sum_{j=1}^K (x_j - \mu)(x_j - \mu)^T p(z_t | x_j, m)$$

- Proposal分布变为高斯分布由 (μ, Σ) 表示的高斯分布, 因此粒子传播由从运动学模型采样修改为对该高斯分布进行采样。

- 权重的计算方式:

$$w = \eta \frac{p(z_t | x_t, m) p(x_t | u_t, x_{t-1}^i) bel(x_{t-1})}{p(x_t | x_{t-1}, u_t, z_t, m) bel(x_{t-1})}$$

$$p(x_t | x_{t-1}, u_t, z_t, m) = \frac{p(z_t | x_t, m) p(x_t | u_t, x_{t-1})}{p(z_t | x_{t-1}, u_t, m)}$$

$$w = p(z_t | x_{t-1}, u_t, m)$$

$$= \int p(z_t | x_t, m) p(x_t | x_{t-1}, u_t) dx_t$$

$$= \sum_{j=1}^{j=K} p(z_t | x_t, m)$$



Fast-SLAM最终优化流程



最终算法流程

- 已知数据:

Require:

\mathcal{S}_{t-1} , the sample set of the previous time step

z_t , the most recent laser scan

u_{t-1} , the most recent odometry measurement

Ensure:

\mathcal{S}_t , the new sample set

- Scan-match和采样:

$$\langle x_{t-1}^{(i)}, w_{t-1}^{(i)}, m_{t-1}^{(i)} \rangle = s_{t-1}^{(i)}$$

// scan-matching

$$x_t'^{(i)} = x_{t-1}^{(i)} \oplus u_{t-1}$$

$$\hat{x}_t^{(i)} = \operatorname{argmax}_x p(x \mid m_{t-1}^{(i)}, z_t, x_t'^{(i)})$$

if $\hat{x}_t^{(i)} = \text{failure}$ **then**

$$x_t^{(i)} \sim p(x_t \mid x_{t-1}^{(i)}, u_{t-1})$$

$$w_t^{(i)} = w_{t-1}^{(i)} \cdot p(z_t \mid m_{t-1}^{(i)}, x_t^{(i)})$$

else

// sample around the mode

for $k = 1, \dots, K$ **do**

$$x_k \sim \{x_j \mid |x_j - \hat{x}^{(i)}| < \Delta\}$$

end for



最终算法流程

- 计算高斯分布：

// compute Gaussian proposal

$$\mu_t^{(i)} = (0, 0, 0)^T$$

$$\eta^{(i)} = 0$$

for all $x_j \in \{x_1, \dots, x_K\}$ **do**

$$\mu_t^{(i)} = \mu_t^{(i)} + x_j \cdot p(z_t | m_{t-1}^{(i)}, x_j) \cdot p(x_t | x_{t-1}^{(i)}, u_{t-1})$$

$$\eta^{(i)} = \eta^{(i)} + p(z_t | m_{t-1}^{(i)}, x_j) \cdot p(x_t | x_{t-1}^{(i)}, u_{t-1})$$

end for

$$\mu_t^{(i)} = \mu_t^{(i)} / \eta^{(i)}$$

$$\Sigma_t^{(i)} = \mathbf{0}$$

for all $x_j \in \{x_1, \dots, x_K\}$ **do**

$$\Sigma_t^{(i)} = \Sigma_t^{(i)} + (x_j - \mu_t^{(i)})(x_j - \mu_t^{(i)})^T \cdot$$

$$p(z_t | m_{t-1}^{(i)}, x_j) \cdot p(x_j | x_{t-1}^{(i)}, u_{t-1})$$

end for

$$\Sigma_t^{(i)} = \Sigma_t^{(i)} / \eta^{(i)}$$

- 从高斯分布中采样并更新权重：

// sample new pose

$$x_t^{(i)} \sim \mathcal{N}(\mu_t^{(i)}, \Sigma_t^{(i)})$$

// update importance weights

$$w_t^{(i)} = w_{t-1}^{(i)} \cdot \eta^{(i)}$$

- 已知位姿的情况下进行地图更新：

// update map

$$m_t^{(i)} = \text{integrateScan}(m_{t-1}^{(i)}, x_t^{(i)}, z_t)$$

// update sample set

$$\mathcal{S}_t = \mathcal{S}_t \cup \{ \langle x_t^{(i)}, w_t^{(i)}, m_t^{(i)} \rangle \}$$

- 已知位姿的情况下进行地图更新：

$$N_{\text{eff}} = \frac{1}{\sum_{i=1}^N (\bar{w}^{(i)})^2}$$

if $N_{\text{eff}} < T$ **then**

$$\mathcal{S}_t = \text{resample}(\mathcal{S}_t)$$



Filter-based SLAM



1、贝叶斯滤波



2、粒子滤波



3、FastSLAM的原理及优化



4、Gmapping的介绍



Gmapping介绍



Gmapping特性

- 目前使用的最为广泛的2D激光SLAM算法
- 在较小的环境中能实现较好的建图效果
- 以FastSLAM为基本原理
- 在FastSLAM的基础上进行了优化1和优化2
- Gmapping没有使用优化3



Gmapping代码分析

- ROS Wrapper

见视频

- openSLAMGmapping

见视频



作业



在Gmapping中实现优化3

- 参考文献 Improved Techniques for Grid Mapping With RBPF



结语

感谢各位聆听!

Thanks for Listening